# RAMVI

ТЕХНИЧЕСКОЕ ЗАДАНИЕ | Портативная платформа локальных LLM, чата, агентов и голосового ввода

Редакция 1.0 · 13 ноября 2026 года · Статус: концепция для реализации · Название: RAMVI (приложение), RAMVI Engine (движок)

Исходная кодовая база: github.com/karabilo214/AI/tree/main/llm_app. Название и визуальный стиль предварительные: проверить товарные знаки и домены до публикации.




**Иллюстрация 1. Обзор будущего приложения (концептуальная инфографика).**

## 1. Назначение и границы продукта

Цель: дать пользователю возможность запустить локальную языковую модель без командной строки, выбрать оптимальную модель под имеющееся оборудование, общаться в чате, диктовать запросы и выполнять задачи с помощью встроенного агента. Приложение распространяется портативно и не требует облачного сервиса для инференса.

| Принцип | Требование |
|---|---|
| **Работа сразу** | Главное окно — чат; при первом старте — короткий мастер с проверкой оборудования и выбором модели. |
| **Портативность** | Запуск из распакованной папки; запись данных в контролируемое место; внешний установщик необязателен. |
| **Offline-first** | Чат, модели, агент и STT работают без сети после предварительной загрузки компонентов. |

| | |
|---|---|
| **Реализм** | Показывать поддерживаемые архитектуры и достоверную оценку ресурсов; не обещать качество или скорость без проверки. |
| **Безопасность** | Инструменты агента, сетевой API, микрофон и доступ к файлам — только по явному выбору пользователя. |

## 1.1. Что не входит в обязательную v1

- Обучение или fine-tuning моделей в интерфейсе; мультимодальное распознавание изображений; полный TTS-диалог; синхронизация между устройствами через облако; произвольные модели вне поддерживаемого списка архитектур.
- Полная совместимость со всеми возможными параметрами OpenAI/Anthropic/Ollama API — только официально заявленный и проверенный набор.
- Автономный агент без ограничений прав доступа или выполняющий действия вне выбранного рабочего пространства.

## 1.2. Основные роли и сценарии

| Роль | Задача |
|---|---|
| **Обычный пользователь** | Начать чат, выбрать модель, надиктовать текст, открыть историю. |
| **Разработчик** | Импортировать GGUF, видеть ресурсы, подключить IDE/агента, запускать безопасные рабочие процессы. |
| **Пользователь агента** | Указать рабочую папку, задать цель, видеть план, подтверждать изменения и итог. |
| **Администратор локального API** | Создавать ключи клиентов, смотреть расход токенов и отключать подключения. |

## 2. Навигация и визуальный язык

Десктоп-интерфейс с левым меню: Чат, Модели, Агент, Подключения, Мониторинг, Настройки. Никаких обязательных технических настроек на главном экране. Статус текущей модели, локального сервера и краткие метрики — в верхней/нижней полосе.

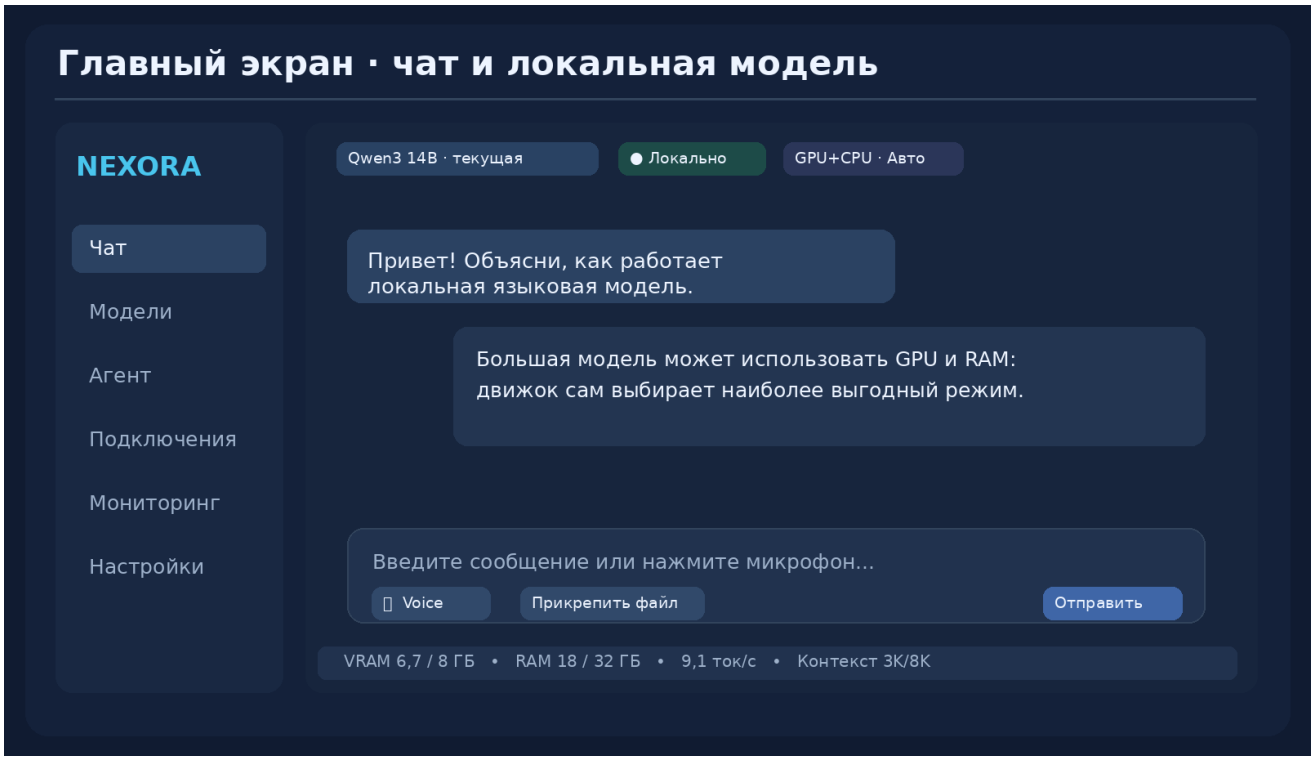



**Иллюстрация 2. Экран чата: модель доступна сразу, Voice — рядом с полем ввода.**

**UI-01 Первый запуск** *[P0]*

Показать проверку ОС, GPU/VRAM, CPU/RAM, свободного диска и доступных бэкендов. Если модель отсутствует — предложить наиболее подходящие варианты и кнопку загрузки. Мастер допускает пропуск каталога для импорта файла.

Приёмка: При первом запуске до начала диалога достаточно выбрать совместимую модель; после повторного запуска история и выбор восстановлены.

**UI-02 Чат** *[P0]*

Новый чат; список диалогов; потоковая выдача; Stop/Regenerate; копирование ответа; очистка; выбор модели; отображение thinking как отдельной сворачиваемой области при поддержке; drag-and-drop текстовых файлов с лимитами.

Приёмка: Пользователь может отправить сообщение, остановить ответ, восстановить диалог и переключить модель без перезапуска GUI.

**UI-03 Состояния интерфейса** *[P0]*

Явно различать: нет модели, загрузка весов, готова, генерирует, ошибка, недостаточно памяти, модель несовместима, API занят, нет доступа к каталогу.

Приёмка: Для каждого состояния задано понятное действие по восстановлению.

**UI-04 Доступность** *[P1]*

Масштабирование 100–200%, клавиатурная навигация, высокий контраст, русская и английская локализации.

Приёмка: Основной пользовательский путь доступен без мыши.

## 3. Каталог моделей и менеджер загрузок

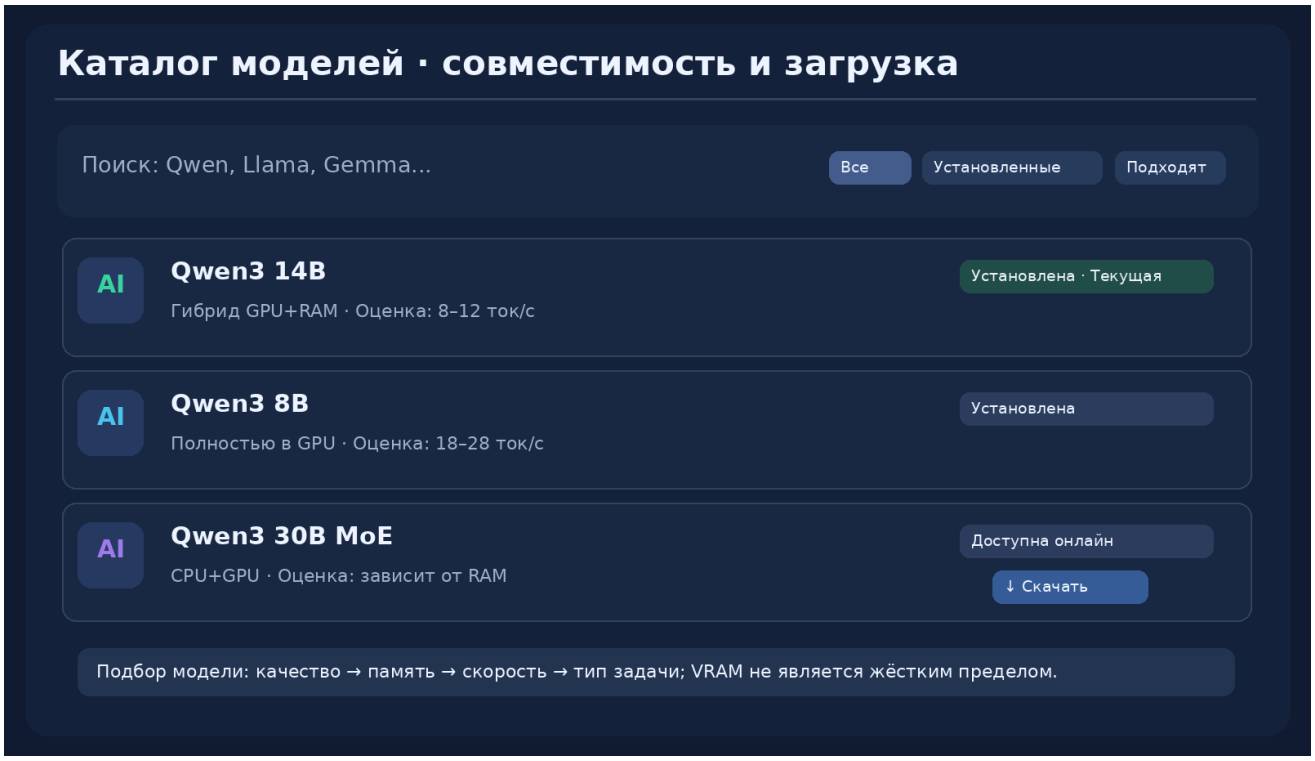



**Иллюстрация 3. Каталог: установленные модели, рекомендации, совместимость и загрузка.**

**MOD-01 Источники каталога** *[P0]*

Загружать онлайн только метаданные из адаптеров доверенных каталогов (например, Hugging Face/Ollama registry при соответствующих правилах использования). Схема провайдера отделена от UI. Обязательны версия, ссылка, размер, контрольная сумма/идентификатор, архитектура, квантование, лицензия, поддерживаемые возможности.

Приёмка: Каталог отображает только подтверждённо поддерживаемые форматы; офлайн показывает последнюю локальную копию данных.

**MOD-02 Управление моделью** *[P0]*

Состояния: доступна → скачивается → проверяется → установлена → текущая → загружена в движок. Операции: скачать, пауза, продолжить, отменить, импортировать локальный файл, удалить, выбрать текущей, посмотреть свойства.

Приёмка: Прерванная загрузка возобновляется по диапазону при поддержке сервера, хеш проверяется до активации; частичный файл не считается установленным.

**MOD-03 Совместимость** *[P0]*

Фильтры: поддерживается движком; запускается на оборудовании; подходит задаче; локальная/сетевая; размер/квантование/контекст; лицензия. Статусы: Рекомендуется, Запускается медленно, Не хватает RAM/диска, Не поддерживается.

Приёмка: Отсутствие полной вместимости в VRAM не даёт автоматический статус «неподходящая».

**MOD-04 Отказоустойчивость** *[P0]*

Проверка места до начала скачивания, атомарная фиксация, ограничения скорости/параллелизма, защита от path traversal, подписанные/проверяемые источники метаданных по возможности.

Приёмка: После выключения питания библиотека не показывает повреждённую модель как готовую.

## 4. Автоматический подбор модели под железо и задачу




**Иллюстрация 4. Подбор модели строится на выполнимости, оценке качества и реальных пробах.**

Важнейшее требование: GPU/VRAM — один из факторов, но не жёсткое ограничение. Планировщик должен оценивать полную VRAM-резидентность, гибрид CPU/GPU, offload из RAM и CPU-only, используя реальные возможности текущей версии llm_app.

**AUTO-01 Профиль оборудования** *[P0]*

Определить CPU, ISA, число ядер, RAM total/available, GPU/vendor, VRAM total/free, CUDA/runtime/driver, SSD/free storage и параметры памяти. Не отправлять fingerprint оборудования наружу без согласия.

Приёмка: Работает на поддерживаемой ОС при наличии и отсутствии NVIDIA; отсутствующая поддержка GPU показывается явно.

**AUTO-02 Профиль задачи** *[P0]*

Режимы: повседневный чат, код, агент, длинный контекст, структурированный JSON, экономия ресурсов. Вручную можно задать приоритет: качество, скорость, экономия RAM, время первого токена.

Приёмка: Смена профиля перестраивает рекомендации без изменения установленных файлов.

**AUTO-03 Проверка выполнимости** *[P0]*

Оценка весов в поддерживаемом формате, KV-cache для выбранного контекста, GPU-постоянных буферов, draft, буферов стриминга, CPU-рабочих массивов и резерва безопасности; сравнение с available RAM/VRAM (не только total). Допускается подкачка в RAM, но не обещается интерактивная скорость при системном swap.

Приёмка: 14B-модель может быть отмечена как выполнимая на GPU 8 ГБ при достаточной RAM и поддерживаемом гибридном плане.

**AUTO-04 Ранжирование** *[P0]*

Сначала отсеять несовместимые форматы/лицензии и невыполнимые планы, затем ранжировать по прогнозу качества на выбранном классе задач, скорости, TTFT, RAM/VRAM и локальным бенчмаркам. Не выводить недоказанный общий рейтинг «умнее».

Приёмка: Пользователь видит причину выбора: качество/задача/расчёт памяти/скорость и 2–3 альтернативы.

**AUTO-05 Контрольный прогон и адаптация** *[P1]*

После скачивания запускать короткий warmup+benchmark на небольшой набор synthetic prompts и реальной длине контекста; измерять пик памяти, TTFT, tok/s, page faults; безопасно скорректировать resident и режим, сохранить результат под ключом model hash+hardware+driver+context.

Приёмка: Нестабильный запуск снижает рейтинг, а OOM приводит к автоматическому безопасному откату плана.

**AUTO-06 Защита от неудачного выбора** *[P0]*

Никогда не менять активную модель посреди запроса без разрешения. При нехватке памяти предлагать: уменьшить контекст, сменить режим, выбрать меньшую модель, закрыть другие задачи.

Приёмка: Невыполнимый план завершается понятной ошибкой, без зависания GUI.

Формула отбора (ориентир, не жёсткий алгоритм): Score = Q_task × Wq + normalized_speed × Ws + normalized_TTFT × Wt − RAM_penalty − instability_penalty. Весовые коэффициенты различаются по профилю. Оценка качества модели должна приходить из проверяемых наборов измерений; скорость — преимущественно из локального профиля.

## 5. Агентная подсистема — заложить архитектуру в v1

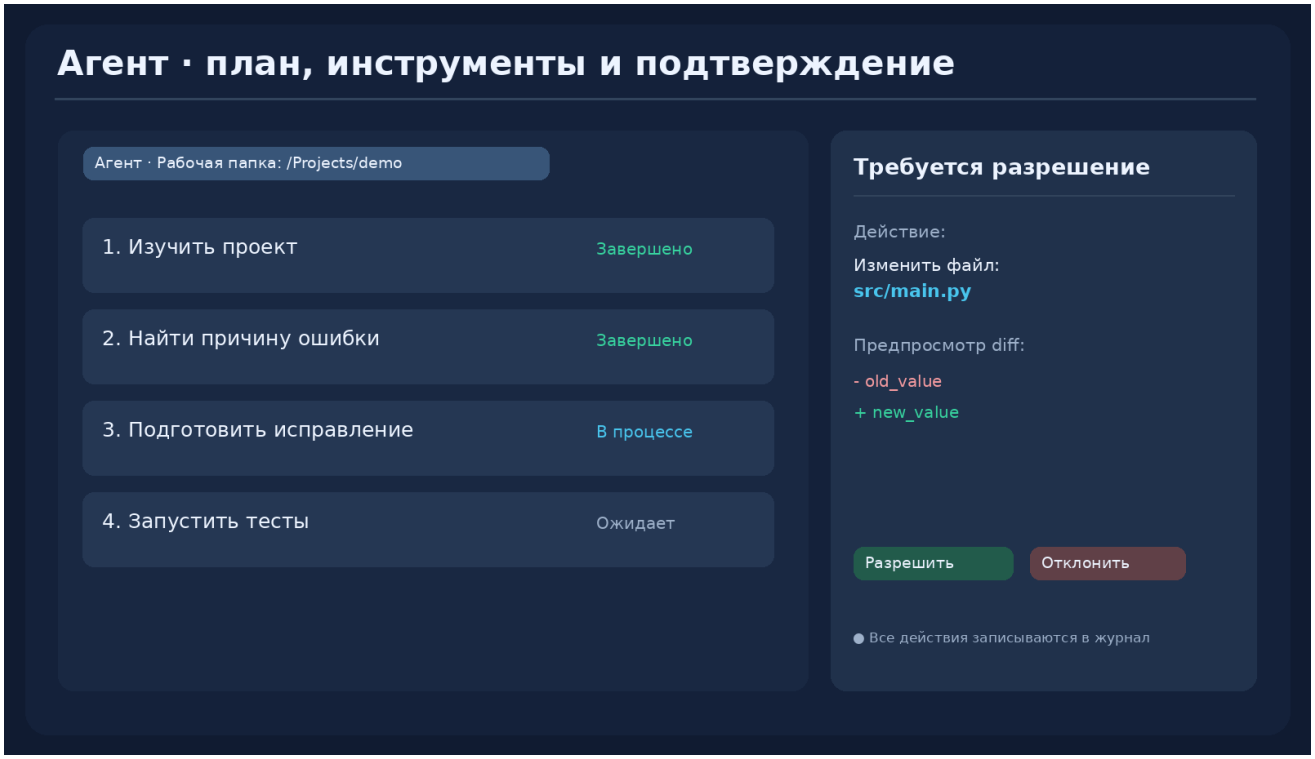



**Иллюстрация 5. Агент: видимый план, действия с файлами и явное подтверждение изменений.**

**AG-01 Цикл агента** *[P0]*

Независимый Agent Runtime: goal → plan → tool proposal → policy check → execution → observation → validation → next step/final. Ограниченный max_steps, max_tokens, max_duration; остановка пользователем.

Приёмка: Агент выполняет несколько шагов и корректно завершает задачу/останавливается по лимиту.

**AG-02 Инструменты** *[P0]*

Минимум: list/read/find файлов, ограниченный grep, diff, создание патча, запись файлов по подтверждению, разрешённый запуск тестов/команд; web/search — отдельная опция, выключенная офлайн. Унифицированная schema инструментов и версионирование.

Приёмка: Действия не выполняются без записи в журнал, выход и ошибки возвращаются в контекст модели.

**AG-03 Границы доступа** *[P0]*

Рабочая папка — явный grant; каноникализация путей, запрет выхода через .. и symlink, исключения для секретов; отдельные разрешения на чтение, запись, терминал и сеть. Команды и записи требуют подтверждения по умолчанию.

Приёмка: Агент не может читать/менять файл вне разрешённой папки; отмена и отказ пользователя безопасны.

**AG-04 Просмотр изменений** *[P0]*

Перед записью — diff; подтверждение одного действия или ограниченной серии; undo/rollback при возможности через снимки файлов; пользователь может отказать, поправить задачу или остановить.

Приёмка: Без подтверждения исходные файлы остаются неизменными.

**AG-05 Защита исполнения** *[P0]*

Команды в отдельном дочернем процессе с ограничением времени, stdout/stderr, cwd и размера вывода; для повышенного риска — sandbox/container при наличии. Не считать один список запрещённых команд достаточной изоляцией.

Приёмка: Превышение лимита прекращает процесс и освобождает ресурсы; разрушительные действия заблокированы/требуют отдельного разрешения.

**AG-06 Качество инструментального использования** *[P0]*

Проверка capability каждой модели (tool calls, JSON, контекст), валидация схемы вызова, повтор только при корректируемой ошибке. Отображать предупреждение, что маленькая модель может плохо планировать действия.

Приёмка: Некорректный tool call не исполняется; агент может сообщить о невозможности безопасно завершить задачу.

**AG-07 Наблюдаемость** *[P1]*

Отображать шаги плана, историю инструментов, время, токены prompt/completion, контекст, статус, таймлайн ошибок; сохранять локально с опцией очистки.

Приёмка: Пользователь может восстановить причину изменения файла по журналу.

**AG-08 Будущие расширения** *[P2]*

Протокол подключаемых инструментов (в перспективе MCP), дополнительные агенты/подзадачи, репозитории Git, browser automation только с явными разрешениями.

Приёмка: Расширение не требует переписывать UI или ядро LLM.

## 6. Голосовой ввод Voice

**VOI-01 Speech-to-text** *[P0]*

Кнопка микрофона в чате и агенте, короткая запись → локальное STT → текст в поле ввода. Для первой версии целесообразен отдельный backend на whisper.cpp или иной подтверждённый offline STT; язык auto/RU/EN/UK; устройство ввода выбирается.

Приёмка: Работает без интернета; текст доступен для редактирования до отправки.

**VOI-02 Разрешения и приватность** *[P0]*

Микрофон включается только нажатием/горячей клавишей; заметный индикатор записи; Stop; звук по умолчанию не сохраняется; понятные ошибки отсутствия микрофона.

Приёмка: После Stop запись прекращается; без разрешения ОС запись не начинается.

**VOI-03 Ресурсы** *[P1]*

STT может выполняться на CPU, пока основная LLM занимает GPU; автоматический выбор STT backend по доступной памяти, ограничение конкуренции и приоритет отзывчивости интерфейса.

Приёмка: Voice не вызывает OOM активной большой модели.

**VOI-04 Следующая версия** *[P2]*

Push-to-talk; VAD/пауза; потоковая транскрипция; optional TTS и полноценный голосовой диалог, отключаемые независимо.

Приёмка: Настройка озвучивания не влияет на режим текстового ввода.

## 7. Подключение внешних приложений и агентов

**API-01 Локальный сервер** *[P0]*

Один процесс движка предоставляет проверенные совместимые маршруты OpenAI/Ollama/Anthropic; слушает 127.0.0.1 по умолчанию; динамический порт/фиксированный порт в настройках, discovery через локальный файл состояния.

Приёмка: Клиент IDE может подключиться и получить потоковый ответ без запуска GUI.

**API-02 Клиенты и ключи** *[P0]*

Для каждого подключённого приложения — отдельный случайный ключ, имя, дата создания, разрешения, last_seen, состояние, счётчики токенов; отзыв немедленно блокирует новые запросы и при необходимости отменяет текущий.

Приёмка: Отключение конкретного клиента не сбрасывает остальные; ключ никогда не показывается целиком повторно.

**API-03 Многозадачность** *[P0]*

Очередь запросов и scheduler: один контекст не может быть перезаписан другой сессией. Fairness, отмена, лимит клиентов, max_concurrent на основании доступной памяти.

Приёмка: Два клиента не смешивают токены, KV-cache, историю и статистику.

**API-04 Сетевой режим** *[P1]*

0.0.0.0 только по явному включению, предупреждение о рисках, обязательная авторизация, ограничение доступа; TLS/прокси для внешней сети.

Приёмка: После установки по умолчанию приложение недоступно извне компьютера.

## 8. Гибридный inference-движок и интеграционный контракт




**Иллюстрация 6. UI и подсистемы независимы от RAMVI Engine.**

Основная база: llm_app/engine.py, gengine.py, gcpu.py, gkernels.py, wcomp.py, moe.py, plan.py, server.py. Поддерживаемый в исходном проекте диапазон — Qwen3 HF/BF16, Qwen3 GGUF и частично Qwen3-MoE/GGUF. Новые архитектуры добавлять отдельными адаптерами после валидации.

**ENG-01 Процессная изоляция** *[P0]*

UI не импортирует тяжёлый Python inference в свой процесс. Engine process общается с Desktop UI через локальный RPC/HTTP и публикует статус/метрики. Падение движка не закрывает окно приложения.

Приёмка: При аварии движка интерфейс остаётся доступным, показывает диагностику и предлагает перезапуск.

**ENG-02 Режимы выполнения** *[P0]*

Размещать слои на GPU, CPU, stream либо hybrid там, где это реализовано. Не предполагать, что любой движок MoE поддерживает те же offload-пути.

Приёмка: Составлен capability map по backend, архитектуре и типу модели.

**ENG-03 Планировщик** *[P0]*

Авто resident, reserve, batch, draft и prefill; профиль измерений; fallback при OOM; журнал фактического плана; продвинутый ручной режим. Резерв VRAM зависит от контекста, KV и runtime, а не фиксированного обещания.

Приёмка: При росте контекста система контролирует ресурсный бюджет и корректно завершает запрос при невозможности продолжать.

**ENG-04 Инструменты генерации** *[P0]*

Streaming, stop, seeds, greedy/sampling в поддерживаемой семантике, metrics TTFT/tok/s/accepted; только совместимый draft tokenizer; поддержка JSON и tool call в пределах реально проверенной реализации.

Приёмка: С эталоном сравниваются последовательность токенов и допуски логитов, а не только текст.

**ENG-05 Управление жизненным циклом** *[P0]*

Load/unload модели, прогрев, отмена, перезапуск бэкенда, освобождение VRAM, безопасное закрытие Loader/CUDA, невозможность переключать модель в середине инструментального шага без явной политики.

Приёмка: После unload память освобождена, повторная загрузка работает без перезапуска desktop.

## 9. Переносимость, упаковка, обновления

**PORT-01 Portable layout** *[P0]*

Версия Windows x64 как стартовая платформа. Запуск после распаковки; приложение и конфигурация в переносимой директории, если есть запись; для read-only USB — явно выбираемый data folder.

Приёмка: Смена буквы диска не ломает пути и историю; сценарий без прав администратора работает.

**PORT-02 Комплектация** *[P0]*

Поставлять UI, backend runtime, native библиотеки и проверенные зависимости; не требовать установки Python/CUDA Toolkit. Нужны совместимые системные драйверы GPU — это явно указать в диагностике.

Приёмка: Чистая поддерживаемая Windows-машина с установленным драйвером запускает приложение без pip и CLI.

**PORT-03 Модели отдельно** *[P0]*

Путь моделей задаётся отдельно от пути приложения; допустим SSD, внешняя флешка или сетевой диск с предупреждением о задержках; импорт существующих моделей без копирования при явном согласии.

Приёмка: Перемещение portable-папки не заставляет повторно скачивать модель при сохранении путей.

**PORT-04 Обновления** *[P1]*

Проверка подписанного манифеста обновлений по согласию; staging в отдельной директории, rollback, миграция локальной базы с backup; офлайн-архив обновлений.

Приёмка: Неудачное обновление не удаляет историю чатов и модели.

## 10. Данные, хранение и API интерфейсов

Рекомендуемое локальное хранилище: SQLite с WAL и миграциями, каталог моделей как JSON-cache, файлы модели вне SQLite. Возможность шифрования чувствительных ключей средствами ОС с учётом портативного режима. Если проект переносится между ПК, потребуется отдельная процедура переноса/повторного ввода ключей.

| Сущность | Основные поля |
|---|---|
| **Model** | id, provider, architecture, quant, sha256, bytes, path, license, installed_at, capabilities |
| **ModelProfile** | model_id, hardware_hash_local, context, plan, TTFT, tokps, peak_ram, peak_vram, tested_at |
| **Chat** | id, title, model_id, created_at, updated_at |
| **Message** | id, chat_id, role, content, token_usage, created_at |
| **AgentRun** | id, objective, workspace, model_id, status, steps, token_usage, started_at, ended_at |

| | |
|---|---|
| **ToolCall** | id, agent_run_id, tool_name, args_redacted, permission, result, duration |
| **ClientKey** | id, client_name, permissions, secret_hash, created_at, last_seen, revoked_at |
| **Download** | id, model_id, source, temp_path, bytes_done, total_bytes, state, checksum |

Внутренние события: model.discovered, download.progress, model.ready, engine.loading, engine.ready, engine.oom, generation.delta, generation.completed, agent.plan, agent.tool_approval_required, agent.tool_result, voice.transcript. События имеют request_id/run_id, monotonic timestamp, version и payload со строгой схемой.

## 11. Безопасность и приватность

- Проверка источников моделей, контрольных сумм, лицензий и запрет исполнения произвольного кода из описаний моделей/шаблонов. GGUF загружается как данные; импорт сторонних Python-моделей только через изолированную доверенную политику.
- Prompt injection: инструкции из файлов, страниц и ответов инструментов не считаются полномочиями; доступ контролирует runtime независимо от выводов модели.
- Секреты (ключи API и токены клиентов) маскируются в UI и логах; сетевое прослушивание выключено по умолчанию; при переносе на USB нельзя молча обещать аппаратную защиту ключей.
- Агент не должен автоматически запускать опасные команды; явные разрешения, диффы, журнал и возможность отзыва доступа обязательны.
- Телеметрия по умолчанию выключена; любые логи или диагностика наружу — только по явному согласию.
- Скачивание и распаковка компонентов ограничены по размеру и путям; защита от подмены манифеста и от удаления произвольных пользовательских файлов.

## 12. Нефункциональные требования

| Категория | Требование / измерение |
|---|---|
| **Отзывчивость** | UI остаётся интерактивным при загрузке, генерации, STT и agent tool execution. Нет блокировок event-loop. |
| **Память** | Никаких обещаний «влезает» без оценки KV, head, draft, временных буферов и резерва. |
| **Производительность** | Показывать TTFT, tok/s, фактический peak VRAM/RAM и CPU/GPU-режим; целевые значения задаются для конкретной модели и железа после baseline. |
| **Надёжность** | Атомарная установка модели, восстановление загрузок, корректная отмена, рестарт engine, локальная история без потерь. |
| **Диагностика** | Логи с request_id, версии engine, model hash, планом памяти, аварийной причиной без раскрытия секретов. |
| **Локализация** | Русский/английский на старте; строки в ресурсах, не зашиты в UI. |

## 13. Этапы реализации и зависимость работ

| Этап | Состав | Результат |
|---|---|---|
| **0. Контракт ядра** | Capability API, модель ресурсов, engine lifecycle, метрики, | UI и backend могут развиваться |

| | | |
|---|---|---|
| | версии схем | независимо. |
| **1. Portable MVP** | UI, чат, история, настройки, запуск engine, импорт моделей | Первый чат без CLI. |
| **2. Каталог и подбор** | Адаптер каталога, resumable download, fingerprint, scoring, локальный benchmark | Автоподбор поддерживает RAM offload. |
| **3. Voice** | Кнопка, локальный STT, управление устройством ввода | Голос → редактируемый текст. |
| **4. Agent MVP** | Runtime, workspace, файловые инструменты, diff, подтверждения, журнал | Контролируемые агентные задачи. |
| **5. Подключения** | API-клиенты, ключи, лимиты, статистика, очередь | Работа внешних агентов и IDE. |
| **6. Укрепление** | Нагрузочные тесты, sandbox, обновление, переносимость | Публичная бета. |

## 14. Экзамены и критерии приёмки релиза

1. Чистый запуск: распаковать приложение на Windows x64 без установленного Python, выбрать модель и начать диалог.
2. Неполная VRAM: Qwen3:14B или аналогичная поддерживаемая модель запускается в гибридном режиме при достаточной RAM, расчёт memory plan и фактические ресурсы отображаются.
3. Смена оборудования: после переноса на другой ПК рекомендуемая модель/план пересчитываются; пользовательские модели и чаты остаются доступными.
4. Offline: при отключённом интернете чат, Voice и файловые инструменты агента продолжают работу.
5. Обрыв скачивания: остановить сеть на середине модели; после возврата сети загрузка продолжается/перепроверяется, повреждённые данные не активируются.
6. Агент: проект доступен только в указанной папке; запрос на изменение файла содержит diff; отказ оставляет файл неизменным; Stop отменяет действие, когда это безопасно.
7. Внешний клиент: два ключа работают раздельно; отзыв одного не останавливает другой; токены и время корректно считаются для каждого клиента.
8. KV/сессии: переключения режима CPU/GPU и последовательное обслуживание нескольких чатов не изменяют состояние чужого запроса; регрессионные тесты сравнивают корректность.
9. Voice: включение только нажатием; локальная транскрипция RU/EN/UK в поле ввода; отказ в разрешении микрофона не ломает чат.
10. Нагрузка и ошибки: OOM, full disk, model corrupt, API disconnect, драйвер недоступен, STT ошибки, падение engine — диагностируются без повреждения данных.

## 15. Риски, допущения и открытые решения

| Риск / вопрос | Позиция для ТЗ |
|---|---|
| **Имя продукта** | RAMVI — приложение, RAMVI Engine — движок; проверить права и домены перед брендингом. |
| **Фреймворк оболочки** | Рекомендуется Tauri + Vue/TypeScript; сравнить размер сборки, portable-режим и зависимости WebView2. |
| **Поддержка моделей** | Начать с Qwen3 GGUF/HF и только подтверждённых возможностей; каталог шире списка совместимости не делать. |
| **Качество агента** | Зависит от модели; в авторанжировании агентных задач учитывать capability tool-use и реальные тесты. |
| **Размер поставки** | Desktop runtime, CPU DLL, Python/CUDA |

| | |
|---|---|
| | зависимости и STT могут быть велики; измерить фактический размер portable-дистрибутива. |
| **Безопасная песочница** | Без отдельной изоляции нельзя обещать полную безопасность команд. |
| **Показатели производительности** | Нужен единый бенчмарк с холодным/тёплым стартом, одинаковыми параметрами и проверкой корректности. |

## 16. Рекомендуемая структура репозитория

Не переносить и не переписывать весь llm_app. Добавить тонкие слои интеграции:

desktop/ (Tauri + Vue UI), service/ (IPC API, engine supervisor, model registry, scheduler), agent/ (runtime, tool adapters, policy, approvals), voice/ (STT adapter), storage/ (SQLite, migrations), packaging/ (portable builds, update manifest), tests/e2e/, llm_app/ (существующий inference core).

Непересекающиеся ответственности должны быть закреплены в интерфейсах. UI не должен знать внутренние детали CUDA Graph или хранения KV, а агент не должен вызывать системные команды вне Tool Runtime.

## 17. Сводка обязательного объёма v1

| Обязательная функция | Да / критерий |
|---|---|
| **Портативный запуск** | Да — из папки, без pip/CLI. |
| **Чат при открытии** | Да — после загрузки/выбора модели. |
| **Каталог, загрузки, импорт** | Да — только поддерживаемые модели и проверяемые источники. |
| **Автоподбор по железу** | Да — включая GPU+RAM/CPU-offload. |
| **Voice STT** | Да — локально и с редактированием текста. |
| **Агентная архитектура** | Да — Agent Runtime и базовые безопасные инструменты. |
| **Доступ внешних агентов** | Да — локальный API и отдельные ключи клиентов. |
| **Метрики ресурсов/токенов** | Да — компактно в UI, подробно на странице мониторинга. |
| **История/настройки** | Да — локальное хранение. |
| **Тесты/документация** | Да — обязательные acceptance/E2E/регрессии. |

Документ является техническим заданием для реализации, а не утверждением, что перечисленные функции уже доступны в llm_app. Визуальные экраны — концептуальные изображения. Требования с меткой P0 — для первой работоспособной версии; P1/P2 — последующие этапы.